

Fundamentos de Inteligencia Artificial Clásica: Técnicas, Métodos y Aplicaciones Antes de la IA Generativa

Luis Chamba-Eras

Editor

2026

Índice general

I	Introducción y Fundamentos	1
II	Aprendizaje Estadístico y Modelos de Clasificación	2
14.	Algoritmo DBSCAN para la Detección de Anomalías	3
14.1.	Introducción	3
14.2.	Fundamentos teóricos	4
14.2.1.	Parámetros críticos y métricas de distancia	4
14.2.2.	Clasificación de los puntos de datos	5
14.2.3.	Definiciones de conectividad y densidad	6
14.2.4.	Complejidad computacional	6
14.2.5.	Ventajas y limitaciones del algoritmo DBSCAN	6
14.3.	Metodología y análisis de la literatura	7
14.3.1.	Sector Automotriz: Diagnóstico OBD y Seguridad	7
14.3.2.	Gas y Energía: Detección de Fraude y Fallos de Sensores	8
14.3.3.	Sector Agua: Comportamiento de Uso Multi-fuente	9
14.3.4.	Ciberseguridad: Redes de Datos y Fibra Óptica	10
14.3.5.	Big Data y Optimización Algorítmica (IA Verde)	10
14.3.6.	Salud, Biología y Comportamiento Humano	11
14.3.7.	Infraestructura y Diagnóstico Estructural	12
14.3.8.	Resumen de Aplicaciones por Sector	12
14.4.	Conclusiones	12

Parte I

Introducción y Fundamentos

Parte II

Aprendizaje Estadístico y Modelos de Clasificación

Capítulo 14

Aplicación del Algoritmo DBSCAN para la Detección de Anomalías en Conjuntos de Datos Ruidosos

Autor: Steeven Daniel Pardo Lima (steeven.pardo@unl.edu.ec)
Técnica asignada: DBSCAN

14.1. Introducción

La detección de anomalías constituye una de las áreas más importantes dentro de la minería de datos y el aprendizaje automático, debido a su capacidad para identificar observaciones, comportamientos o eventos que se desvían significativamente de los patrones considerados normales. Estos comportamientos anómalos pueden representar fallos operativos, intentos de fraude, intrusiones de seguridad, defectos de fabricación o eventos críticos que requieren atención inmediata [1, 2].

En la actualidad, el crecimiento acelerado de los sistemas inteligentes, las infraestructuras conectadas y el Internet de las Cosas (IoT) ha provocado una generación masiva de datos provenientes de sensores, dispositivos móviles, sistemas industriales y redes de comunicación. Como consecuencia, la detección temprana de anomalías se ha convertido en un requisito fundamental para garantizar la seguridad, confiabilidad y eficiencia de dichos sistemas [3, 4].

Los enfoques tradicionales para la detección de anomalías suelen depender de modelos supervisados que requieren grandes cantidades de datos etiquetados. Sin embargo, en numerosos escenarios reales resulta difícil disponer de ejemplos representativos de todos los posibles fallos o ataques. Esta limitación ha impulsado el uso de técnicas de aprendizaje no supervisado capaces de descubrir patrones ocultos directamente a partir de los datos sin necesidad de etiquetas previas [5, 6].

Dentro de estas técnicas, el algoritmo **DBSCAN (Density-Based Spatial Clustering of Applications with Noise)** se ha consolidado como una de las metodologías más utilizadas para el análisis de agrupamientos y detección de anomalías. Introducido por Ester et al. en 1996, DBSCAN identifica regiones densamente pobladas de datos y clasifica automáticamente como ruido aquellos puntos que no pertenecen a ninguna región densa. Esta característica resulta especialmente valiosa en aplicaciones donde las anomalías representan una pequeña fracción del conjunto total de observaciones [7, 8].

A diferencia de algoritmos de agrupamiento tradicionales como K-means, DBSCAN no requiere especificar previamente el número de grupos presentes en los datos y posee la capacidad de descubrir estructuras de forma arbitraria. Asimismo, presenta una elevada robustez frente a

ruido, valores atípicos y distribuciones complejas, características que lo han convertido en una herramienta ampliamente utilizada en ámbitos como la ciberseguridad, la medicina, la monitorización industrial, los sistemas energéticos inteligentes y el análisis de grandes volúmenes de datos [9–11].

La relevancia actual de DBSCAN se refleja en la gran cantidad de investigaciones recientes que proponen extensiones y variantes orientadas a mejorar su escalabilidad y capacidad de detección. Entre ellas destacan **kNN-DBSCAN**, diseñado para el procesamiento eficiente de conjuntos de datos de alta dimensionalidad [8]; **SensorDBSCAN**, que integra aprendizaje activo y representaciones obtenidas mediante Transformers para reducir la necesidad de datos etiquetados [6]; y **KM-DBSCAN**, enfocado en estrategias de reducción de datos para aplicaciones de inteligencia artificial sostenible o Green AI [12].

Diversos estudios recientes han demostrado la efectividad de DBSCAN para detectar amenazas emergentes en redes de fibra óptica [3], identificar robos de energía en redes eléctricas inteligentes [11], localizar fallos en infraestructuras de telecomunicaciones [4], descubrir patrones anómalos en sistemas de diagnóstico automotriz [13] y monitorizar la salud estructural de puentes mediante técnicas híbridas de aprendizaje automático [14]. Estas aplicaciones evidencian la versatilidad del algoritmo y su capacidad para adaptarse a dominios con características muy diferentes.

En este contexto, el presente capítulo tiene como objetivo presentar los fundamentos teóricos del algoritmo DBSCAN, describir sus principios matemáticos y analizar su aplicación en la detección de anomalías dentro de distintos sectores estratégicos. Para ello se realiza una revisión de literatura reciente que permite identificar tendencias actuales, ventajas, limitaciones y líneas futuras de investigación relacionadas con el agrupamiento basado en densidad y el aprendizaje no supervisado.

14.2. Fundamentos teóricos

El algoritmo **DBSCAN (Density-Based Spatial Clustering of Applications with Noise)** pertenece a la familia de algoritmos de agrupamiento basados en densidad. Su principio fundamental establece que los grupos o clústeres corresponden a regiones del espacio de características donde existe una alta concentración de observaciones, mientras que las anomalías se encuentran en regiones de baja densidad o completamente aisladas [7, 8].

A diferencia de métodos particionales como K-means, que buscan minimizar la distancia entre puntos y centroides, DBSCAN construye agrupamientos a partir de relaciones de vecindad local. Gracias a esta estrategia, el algoritmo puede identificar grupos con formas arbitrarias, detectar automáticamente valores atípicos y operar sin necesidad de conocer previamente el número de clústeres presentes en el conjunto de datos [9, 10].

Estas características han convertido a DBSCAN en una de las técnicas más utilizadas para detección de anomalías, minería de datos espaciales, ciberseguridad, bioinformática y sistemas industriales inteligentes [3, 11, 15].

14.2.1. Parámetros críticos y métricas de distancia

El funcionamiento de DBSCAN depende principalmente de dos hiperparámetros que determinan la noción de densidad dentro del espacio de datos [7, 16]:

1. **Eps (ϵ)**: radio máximo utilizado para definir la vecindad de un punto.
2. **MinPts**: número mínimo de observaciones necesarias dentro de una vecindad para considerar que existe una región densa.

La selección adecuada de estos parámetros es fundamental para el rendimiento del algoritmo. Valores excesivamente pequeños de ε generan numerosos puntos de ruido, mientras que valores demasiado grandes pueden fusionar grupos diferentes en un único clúster [16, 17].

La métrica más empleada para medir proximidad es la distancia euclidiana:

$$d(p, q) = \sqrt{\sum_{k=1}^n (p_k - q_k)^2} \quad (14.1)$$

donde p y q representan dos observaciones dentro de un espacio de n dimensiones.

La vecindad de radio ε se define como:

$$N_\varepsilon(q) = \{p \in D \mid \text{dist}(p, q) \leq \varepsilon\} \quad (14.2)$$

Aunque la distancia euclidiana es la más utilizada, diversos estudios han empleado otras métricas para mejorar el desempeño en dominios específicos. Por ejemplo, Ismail et al. [9] compararon las distancias Euclidiana y Manhattan para la detección de rebaños ganaderos, observando variaciones significativas en la formación de agrupamientos. De forma similar, Zhou et al. [18] utilizaron coeficientes de correlación de distancia para analizar patrones de consumo de agua y energía en ciudades inteligentes.

14.2.2. Clasificación de los puntos de datos

Una vez definida la vecindad local, DBSCAN clasifica cada observación en una de tres categorías fundamentales [7, 8].




Figura 14.1: Clasificación de puntos en DBSCAN según su densidad: puntos núcleo, puntos frontera y puntos de ruido.

- **Puntos núcleo (Core Points):** poseen al menos MinPts vecinos dentro de su radio ε . Constituyen el núcleo de un agrupamiento y son responsables de iniciar el proceso de expansión de clústeres [7].
- **Puntos frontera (Border Points):** no cumplen el requisito de densidad para ser núcleo, pero se encuentran dentro de la vecindad de un punto núcleo. Estos puntos forman parte del agrupamiento, aunque no pueden expandirlo [10].

- **Puntos de ruido (Noise Points):** no pertenecen a ningún agrupamiento ni satisfacen los criterios de densidad establecidos. En aplicaciones de detección de anomalías, estos puntos suelen representar eventos sospechosos, fallos o comportamientos atípicos [5, 11].

La capacidad de identificar automáticamente puntos de ruido constituye una de las principales ventajas de DBSCAN frente a otros algoritmos de agrupamiento tradicionales [1].

14.2.3. Definiciones de conectividad y densidad

El proceso de construcción de agrupamientos en DBSCAN se basa en relaciones de conectividad definidas mediante la densidad local [8].

1. **Alcanzabilidad directa por densidad:** un punto p es directamente alcanzable desde q si q es un punto núcleo y p pertenece a su vecindad.
2. **Alcanzabilidad por densidad:** un punto puede alcanzarse a través de una cadena de puntos núcleo conectados.
3. **Conectividad por densidad:** dos puntos están conectados si ambos son alcanzables desde un mismo punto núcleo.

Estas relaciones permiten construir agrupamientos complejos sin imponer restricciones geométricas sobre la forma de los clústeres [7]. Esta propiedad resulta especialmente útil en aplicaciones reales donde los datos rara vez siguen distribuciones esféricas o lineales.

14.2.4. Complejidad computacional

Uno de los principales desafíos históricos de DBSCAN ha sido su costo computacional. El algoritmo requiere realizar búsquedas de vecinos para cada observación del conjunto de datos, lo que puede resultar costoso en espacios de alta dimensionalidad [8].

Cuando se utilizan estructuras espaciales eficientes como KD-Trees o Ball Trees, la complejidad puede aproximarse a:

$$O(n \log n) \quad (14.3)$$

Sin embargo, en escenarios de alta dimensionalidad o cuando no es posible emplear índices espaciales adecuados, la complejidad puede aumentar hasta:

$$O(n^2) \quad (14.4)$$

Este problema ha motivado el desarrollo de variantes escalables como **kNN-DBSCAN**, capaz de procesar miles de millones de observaciones utilizando arquitecturas paralelas y distribuidas [8].

14.2.5. Ventajas y limitaciones del algoritmo DBSCAN

Las principales ventajas identificadas en la literatura son:

- No requiere especificar previamente el número de clústeres [7].
- Detecta automáticamente ruido y valores atípicos [1].
- Identifica agrupamientos de forma arbitraria [9].
- Presenta buen desempeño en problemas de detección de anomalías [11].

- Puede combinarse con técnicas modernas de aprendizaje profundo y aprendizaje activo [6].

No obstante, también presenta limitaciones importantes:

- Sensibilidad a la selección de ε y MinPts [16].
- Dificultad para trabajar con conjuntos de datos de densidad variable [10].
- Degradación del rendimiento en espacios de alta dimensionalidad [8].
- Dependencia de la métrica de distancia utilizada [9].

Para superar estas limitaciones se han desarrollado variantes híbridas como LOF-DBSCAN [10], KM-DBSCAN [12], SensorDBSCAN [6] y diversos enfoques semi-supervisados basados en aprendizaje activo [19].

Tabla 14.1: Comparación conceptual entre DBSCAN y K-means

Característica	DBSCAN	K-means
Número de clústeres requerido	No	Sí
Detección de ruido	Sí	No
Formas arbitrarias	Sí	Limitado
Sensibilidad a outliers	Baja	Alta
Escalabilidad	Media	Alta

14.3. Metodología y análisis de la literatura

Con el objetivo de evaluar el estado actual del algoritmo DBSCAN en tareas de detección de anomalías, se realizó una revisión de literatura enfocada en aplicaciones industriales, científicas y tecnológicas publicadas entre 2019 y 2026. Los trabajos analizados fueron recuperados de bases de datos reconocidas internacionalmente como IEEE Xplore, ACM Digital Library, SpringerLink, Nature Scientific Reports y BioMed Central.

Los criterios de inclusión consideraron investigaciones que utilizaran DBSCAN como algoritmo principal o como parte de arquitecturas híbridas orientadas al agrupamiento, detección de anomalías, reducción de dimensionalidad, aprendizaje semi-supervisado o procesamiento de grandes volúmenes de datos. Asimismo, se priorizaron estudios con validación experimental y métricas cuantitativas de desempeño.

A partir de la revisión realizada, las aplicaciones identificadas fueron clasificadas en siete dominios principales: automotriz, energía y gas, agua, ciberseguridad, inteligencia artificial sostenible, salud y ciencias biológicas, e infraestructura inteligente. Esta clasificación permite comprender cómo las propiedades fundamentales del agrupamiento basado en densidad han favorecido la adopción de DBSCAN en múltiples sectores estratégicos.

14.3.1. Sector Automotriz: Diagnóstico OBD y Seguridad

Los vehículos modernos generan grandes cantidades de información mediante sistemas electrónicos embarcados. Los sistemas tradicionales de diagnóstico a bordo (OBD) se encuentran diseñados para detectar únicamente fallos previamente definidos por los fabricantes, lo que limita su capacidad para identificar anomalías desconocidas o comportamientos emergentes [13].

Con el propósito de superar estas limitaciones, Vučinić et al. [13] propusieron una arquitectura basada en reducción de dimensionalidad mediante t-SNE seguida de agrupamiento utilizando

DBSCAN. El modelo fue evaluado utilizando instantáneas reales de datos OBD y logró precisiones superiores al 92 % para diferentes escenarios de operación del motor.

Una de las contribuciones más relevantes de dicho estudio fue la incorporación de técnicas de Inteligencia Artificial Explicable (XAI), concretamente valores SHAP, permitiendo identificar las variables responsables de la detección de anomalías. Esta característica resulta especialmente importante en sistemas críticos donde los técnicos requieren comprender el origen de una alerta antes de realizar acciones correctivas [13].

De manera complementaria, Ivanov et al. [6] desarrollaron SensorDBSCAN, una metodología semi-supervisada que combina aprendizaje activo, aprendizaje contrastivo y agrupamiento por densidad. Los resultados mostraron que es posible alcanzar elevados niveles de precisión utilizando menos del 1 % de datos etiquetados, reduciendo significativamente los costos asociados a la generación de conjuntos de entrenamiento.

Los resultados observados evidencian que DBSCAN constituye una alternativa eficaz para detectar fallos complejos, degradaciones progresivas del rendimiento y comportamientos anómalos que difícilmente podrían ser identificados mediante sistemas basados únicamente en reglas.

14.3.2. Gas y Energía: Detección de Fraude y Fallos de Sensores

El monitoreo de recursos críticos como el gas y la electricidad presenta desafíos de densidad desigual en los datos. Para la detección de anomalías en medidores de flujo de gas, se ha propuesto el algoritmo **LOF-DBSCAN** [7, 10]. Esta técnica utiliza el *Factor de Valor Atípico Local (LOF)* para eliminar ruido antes del *clustering*, mejorando la identificación de fallos en sensores de presión y temperatura [9, 20].

En el ámbito de las **redes eléctricas inteligentes (Smart Grids)**, DBSCAN se utiliza para identificar el robo de electricidad y pérdidas no técnicas [1, 11]. Al combinar DBSCAN con clasificadores como **Random Forest**, se logra aumentar la robustez del modelo frente a comportamientos de consumo muy variables [21]. Asimismo, en sistemas de **control transactivo**, el *clustering* permite establecer líneas base de comportamiento del consumidor para detectar ofertas maliciosas en el mercado energético [8, 22].




Figura 14.2: Resultados del agrupamiento mediante el algoritmo DBSCAN estándar aplicado a datos de medidores de gas [10]

14.3.3. Sector Agua: Comportamiento de Uso Multi-fuente

La detección de anomalías en el consumo de agua se beneficia de la correlación con otros recursos. Un estudio innovador propone el uso de información **multi-fuente** (agua + electricidad) procesada mediante la función de distribución **Copula** y el algoritmo **DBSCAN** [13, 18]. Este enfoque permite analizar patrones de consumo horario y detectar comportamientos inusuales en entornos urbanos inteligentes [3, 18].

Tabla 14.2: Características del enfoque multi-fuente aplicado al sector agua

Característica	Aplicación en Agua	Beneficio Técnico
Datos	Series temporales de consumo horario [18]	Captura patrones de fuga o uso inusual [18]
Métrica	Coeficiente de correlación de distancia [13]	Evita el sesgo de una sola fuente de datos [13]
Resultado	Detección de usuarios sospechosos [18]	Reduce falsos positivos en <i>smart cities</i> [3]




Figura 14.3: Visualización del agrupamiento por densidad de los coeficientes de correlación de distancia para detectar comportamientos de consumo anómalos [18]

14.3.4. Ciberseguridad: Redes de Datos y Fibra Óptica

La protección de infraestructuras críticas de red se beneficia de la capacidad de **DBSCAN** para manejar ruido. En redes de fibra óptica, el análisis del **Estado de Polarización (SOP)** mediante DBSCAN permite detectar amenazas emergentes como la escucha clandestina o vibraciones mecánicas sospechosas en el cableado [3]. Para la seguridad de red en general, el algoritmo se utiliza en el filtrado de alarmas multicapas, empleando reglas de inferencia **Rete** para agrupar alertas correlacionadas y reducir significativamente la fatiga de alertas en los centros de operaciones de seguridad [2]. Además, en entornos con datos desbalanceados como el dataset **BoT-IoT**, DBSCAN ha demostrado ser una herramienta robusta para la detección de intrusiones frente a ataques complejos de denegación de servicio [1].

14.3.5. Big Data y Optimización Algorítmica (IA Verde)

La evolución hacia una inteligencia artificial sostenible ha dado lugar al desarrollo de **KM-DBSCAN**, un marco diseñado para la **IA Verde (Green AI)** [12]. Este método utiliza K-means para comprimir el dataset en centroides antes de aplicar DBSCAN, logrando reducciones de datos de hasta el 90% y disminuyendo drásticamente el consumo energético y las emisiones de carbono durante el entrenamiento [12]. Para desafíos de alta dimensionalidad, se ha introducido el algoritmo **kNN-DBSCAN**, que utiliza gráficos de vecinos más cercanos para escalar el proceso de clustering en sistemas distribuidos [8]. Otras innovaciones incluyen la **distancia de conectividad de densidad (dc-dist)**, que unifica teóricamente a DBSCAN con otros métodos de agrupamiento [7], y algoritmos específicos para detectar corrupción de datos a gran escala como **PAACDA** [21].




Figura 14.4: Fases del algoritmo KM-DBSCAN: reducción del conjunto de datos mediante centroides de K-means y agrupamiento posterior por densidad [12]

14.3.6. Salud, Biología y Comportamiento Humano

Las aplicaciones de **DBSCAN** se extienden al análisis de sistemas biológicos y comportamiento animal. En la monitorización de ganado, el algoritmo permite detectar animales aislados o comportamientos atípicos que sugieren enfermedades [9]. En medicina, DBSCAN es fundamental en la **conectómica cerebral** para mapear redes neuronales y predecir la recuperación funcional de pacientes tras cirugías de tumores cerebrales [23]. En genética, se emplea para identificar grupos de genes con expresiones específicas [15], mientras que en la industria alimentaria se utiliza para garantizar la trazabilidad de productos como el té mediante el análisis de datos de procedencia [17].




Figura 14.5: Representación 3D de coordenadas de estimulación funcional en la plantilla cerebral MNI tras el análisis de agrupamiento espacial [23]

14.3.7. Infraestructura y Diagnóstico Estructural

Finalmente, en la salud estructural de obras civiles, **DBSCAN** permite identificar daños en puentes y túneles analizando datos de sensores de vibración [14]. La capacidad del algoritmo para discernir entre variaciones ambientales normales y cambios estructurales anómalos es vital para el mantenimiento preventivo de infraestructuras críticas [14]. En términos generales, la literatura destaca que, aunque existen múltiples técnicas de detección de valores atípicos, **DBSCAN** se mantiene como uno de los pilares más versátiles y confiables en la ciencia de datos actual [24, 25].

14.3.8. Resumen de Aplicaciones por Sector

Tabla 14.3: Resumen de Aplicaciones por Sector

Sector	Técnica Principal / Variante	Referencia
Industrial (ICS)	SensorDBSCAN + Active Learning	[5, 6]
Automotriz	t-SNE + DBSCAN + SHAP	[13]
Energía	Hybrid Random Forest-DBSCAN	[18]
Ciberseguridad	Rete Rule Inference + DBSCAN	[2]
IA Verde	KM-DBSCAN (Data Reduction)	[12]
Salud	Parcellation-based Connectomics	[23]
Agua	Multi-source Copula-DBSCAN	[18]

14.4. Conclusiones

El algoritmo **DBSCAN** se consolida como una herramienta fundamental para el aprendizaje no supervisado en sectores de alto impacto, debido a su capacidad única para modelar la “normalidad” operativa a través de regiones densas, aislando automáticamente cualquier comportamiento divergente como puntos de ruido. Esta propiedad es esencial en la gestión de servicios públicos y ciberseguridad industrial, donde la identificación de anomalías —ya sean fugas de agua, robos de energía o ataques de *Día Cero*— no requiere de conjuntos de datos etiquetados previamente, superando así la limitación del desbalance de clases inherente a estos entornos. Su flexibilidad para descubrir agrupamientos de formas arbitrarias asegura una representación

fiel de los patrones de consumo y operación que los métodos basados en centroides no logran capturar con la misma precisión.

A pesar de sus limitaciones tradicionales relacionadas con la sensibilidad a los parámetros y el costo computacional, la investigación actual demuestra una transición exitosa hacia arquitecturas de hibridación y semi-supervisión. Innovaciones como **KNN-DBSCAN** para el manejo de Big Data y **SensorDBSCAN**, que integra codificadores basados en Transformers, evidencian que la combinación del clustering por densidad con técnicas modernas de extracción de características permite alcanzar precisiones superiores al 90 % con un esfuerzo de etiquetado humano mínimo. Asimismo, el surgimiento de marcos como **KM-DBSCAN** subraya una tendencia hacia la **IA Verde (Green AI)**, logrando reducciones masivas en el volumen de datos y en la huella de carbono del entrenamiento sin sacrificar la capacidad de detección. El futuro de la técnica reside en su integración en dispositivos de borde (*edge computing*), garantizando una respuesta autónoma y de baja latencia ante emergencias sistémicas.

Referencias

- [1] Gutierrez Portela Fernando, Almenares Mendoza Florina, and Calderon Benavides Liliana. Evaluation of the performance of unsupervised learning algorithms for intrusion detection in unbalanced data environments. *IEEE Access*, 12:190134–190157, 2024. ISSN 21693536. doi:[10.1109/ACCESS.2024.3516615](https://doi.org/10.1109/ACCESS.2024.3516615).
- [2] Charvi Bannur, Chaitra Bhat, Kushagra Singh, Shrirang Ambaji Kulkarni, and Mrityunjay Doddamani. Paacda: Comprehensive data corruption detection algorithm. *IEEE Access*, 11:24908–24934, 2023. ISSN 21693536. doi:[10.1109/ACCESS.2023.3253022](https://doi.org/10.1109/ACCESS.2023.3253022).
- [3] Leyla Sadighi, Stefan Karlsson, Carlos Natalino, and Marija Furdek. ML-based state of polarization analysis to detect emerging threats to optical fiber security. *IEEE Transactions on Network and Service Management*, 23:432–442, 2026. ISSN 19324537. doi:[10.1109/TNSM.2025.3607022](https://doi.org/10.1109/TNSM.2025.3607022).
- [4] Christopher Mendoza and Michael P. McGarry. The network link outlier factor (nlof) for fault localization. *IEEE Open Journal of the Communications Society*, 1:1539–1550, 10 2020. ISSN 2644125X. doi:[10.1109/OJCOMS.2020.3025663](https://doi.org/10.1109/OJCOMS.2020.3025663).
- [5] Piotr Sobonski and Utz Roedig. Comparison of industrial control system anomaly detection methods. In *RICSS 2024 - Proceedings of the 2024 Workshop on Re-design Industrial Control Systems with Security, Co-Located with: CCS 2024*, pages 79–85. Association for Computing Machinery, Inc, 11 2024. ISBN 9798400712265. doi:[10.1145/3689930.3695211](https://doi.org/10.1145/3689930.3695211).
- [6] Petr Ivanov, Maria Shtark, Alexander Kozhevnikov, Maksim Golyadkin, Dmitry Botov, and Ilya Makarov. Sensordbscan: Semi-supervised active learning powered method for anomaly detection and diagnosis. *IEEE Access*, 13:25186–25197, 2025. ISSN 21693536. doi:[10.1109/ACCESS.2025.3537649](https://doi.org/10.1109/ACCESS.2025.3537649).
- [7] Anna Beer, Andrew Draganov, Ellen Hohma, Philipp Jahn, Christian M.M. Frey, and Ira Assent. Connecting the dots - density-connectivity distance unifies dbscan, k-center and spectral clustering. In *Proceedings of the ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 80–92. Association for Computing Machinery, 8 2023. ISBN 9798400701030. doi:[10.1145/3580305.3599283](https://doi.org/10.1145/3580305.3599283).
- [8] Youguang Chen, William Ruys, and George Biros. Knn-dbscan: A dbscan in high dimensions. *ACM Transactions on Parallel Computing*, 12, 2 2025. ISSN 23294957. doi:[10.1145/3701624](https://doi.org/10.1145/3701624).
- [9] Zool Hilmi Ismail, Alan Kh ng Kean Chun, and Mohd Ibrahim Shapiai Razak. Efficient herd - outlier detection in livestock monitoring system based on density - based spatial clustering. *IEEE Access*, 7:175062–175070, 2019. ISSN 21693536. doi:[10.1109/ACCESS.2019.2952912](https://doi.org/10.1109/ACCESS.2019.2952912).
- [10] Xichao Yue, Chaoqun Wang, Yong Wang, Le Chen, Weifei Wang, and Yuhang Lei. Gas flow meter anomaly data detection based on fused lof-dbscan algorithm. In *ACM International Conference Proceeding Series*, pages 503–508. Association for Computing Machinery, 11 2022. ISBN 9781450397056. doi:[10.1145/3581807.3581881](https://doi.org/10.1145/3581807.3581881).

- [11] Ali Jaber Almalki. Unsupervised learning with hybrid models for detecting electricity theft in smart grids. *IEEE Access*, 12:187027–187040, 2024. ISSN 21693536. doi:[10.1109/ACCESS.2024.3498733](https://doi.org/10.1109/ACCESS.2024.3498733).
- [12] Mohamed Yasser AboElsaad, Mohamed Farouk, and Hatem A. Khater. Km-dbscan: an enhanced density and centroid based border detection framework for data reduction towards green ai. *Scientific reports*, 16, 12 2026. ISSN 20452322. doi:[10.1038/s41598-026-40062-z](https://doi.org/10.1038/s41598-026-40062-z).
- [13] Veljko Vučinić, Luca Seidel, Nikola Lukežić, Frank Hantschel, Thomas Kotschenreuther, Dragan Aleksendrić, and Eric Sax. Anomaly detection for vehicle diagnostics based on obd snapshots with cause investigation. *IEEE Access*, 14:24765 – 24785, 2026. ISSN 21693536. doi:[10.1109/ACCESS.2026.3664118](https://doi.org/10.1109/ACCESS.2026.3664118).
- [14] Seyed Soroush Pakzad and Amir R. Masoodi. Early damage detection in bridges using a variational autoencoder-based hybrid unsupervised learning framework. *Scientific Reports*, 16, 12 2026. ISSN 20452322. doi:[10.1038/s41598-025-31115-w](https://doi.org/10.1038/s41598-025-31115-w).
- [15] Viktor Vedelek, Balázs Vedelek, and Rita Sinka. Machine learning analysis of drosophila testis transcriptomic data reveals potential regulatory sequences. *BioData Mining*, 19:123–135, 12 2026. ISSN 17560381. doi:[10.1186/s13040-026-00552-2](https://doi.org/10.1186/s13040-026-00552-2).
- [16] Momotaz Begum, Mehedi Hasan Shuvo, Md Golam Mostofa, Abm Kamrul Islam Riad, Md Arabin Islam Talukder, Mst Shapna Akter, and Hossain Shahriar. M-dbscan: Modified dbscan clustering algorithm for detecting and controlling outliers. In *Proceedings of the ACM Symposium on Applied Computing*, pages 1034–1035. Association for Computing Machinery, 4 2024. ISBN 9798400702433. doi:[10.1145/3605098.3636188](https://doi.org/10.1145/3605098.3636188).
- [17] Honggang Yang, Shaowen Li, Lijing Tu, Rongrong Ma, and Yin Chen. Unsupervised outlier detection mechanism for tea traceability data. *IEEE Access*, 10:94818–94831, 2022. ISSN 21693536. doi:[10.1109/ACCESS.2022.3204760](https://doi.org/10.1109/ACCESS.2022.3204760).
- [18] Wenqing Zhou, Chaoqiang Chen, Qin Yan, Bin Li, Kang Liu, Yingjun Zheng, Hongming Yang, Hui Xiao, and Sheng Su. Anomaly usage behavior detection based on multi-source water and electricity consumption information. *IEEE Access*, 13:12215–12224, 2025. ISSN 21693536. doi:[10.1109/ACCESS.2025.3525726](https://doi.org/10.1109/ACCESS.2025.3525726).
- [19] Maria Shtark, Alexander Kozhevnikov, Petr Ivanov, and Ilya Makarov. Poster abstract: Minimizing labeling efforts for fault detection and diagnosis. pages 666–667. Association for Computing Machinery (ACM), 5 2025. ISBN 9798400714795. doi:[10.1145/3715014.3724060](https://doi.org/10.1145/3715014.3724060).
- [20] Huangzhi Xia, Limin Chen, Dongyan Wang, and Xiaotong Lu. Improved denclue outlier detection algorithm with differential privacy and attribute fuzzy priority relation ordering. *IEEE Access*, 11:90283–90297, 2023. ISSN 21693536. doi:[10.1109/ACCESS.2023.3307190](https://doi.org/10.1109/ACCESS.2023.3307190).
- [21] Abdulmalik Shehu Yaro, Filip Maly, Pavel Prazak, and Karel Maly. Outlier detection performance of a modified z-score method in time-series rss observation with hybrid scale estimators. *IEEE Access*, 12:12785–12796, 2024. ISSN 21693536. doi:[10.1109/ACCESS.2024.3356731](https://doi.org/10.1109/ACCESS.2024.3356731).
- [22] Nasheen Nur, Siddharth Sridhar, Seemita Pal, Aditya Ashok, and Vinay C. Amatya. A clustering approach for consumer baselining and anomaly detection in transactive control. In *e-Energy 2019 - Proceedings of the 10th ACM International Conference on Future Energy Systems*, pages 516–521. Association for Computing Machinery, Inc, 6 2019. ISBN 9781450366717. doi:[10.1145/3307772.3331028](https://doi.org/10.1145/3307772.3331028).

- [23] Roberto Altieri, Ciro De Luca, Giovanni Maria De Martino, Assunta Virtuoso, Sergio Corvino, Giuseppe Pontillo, Oreste de Divitiis, Giuseppe La Rocca, Matteo Monticelli, Pietro Zeppa, Fabio Cofano, Antonio Melcarne, Carola Vera Junemann, Francesco Zenga, Daniela Pacella, Michele Papa, Diego Garbossa, Giovanni Cirillo, and Manlio Barbarisi. Unlocking the mind: brain mapping for the exploratory quest of functional and cognitive networks in awake neurosurgery. *Neurosurgical Review*, 49:365, 4 2026. ISSN 1437-2320. doi:[10.1007/s10143-026-04225-w](https://doi.org/10.1007/s10143-026-04225-w).
- [24] Lin Ni, Shuai Zhang, Kun Huang, and Yifan Wang. Multi-level screening method for network security alarms based on dbscan algorithm and rete rule inference. *Scientific Reports*, 16:412–530, 1 2026. ISSN 20452322. doi:[10.1038/s41598-026-36369-6](https://doi.org/10.1038/s41598-026-36369-6).
- [25] Qiong Huang and Yu Huang. A forest firefighting task area division method based on the sw-dbscan algorithm. *Scientific reports*, 16:1–27, 12 2026. ISSN 20452322. doi:[10.1038/s41598-026-42407-0](https://doi.org/10.1038/s41598-026-42407-0).